

第 5 章 无约束非线性规划

第 1 节 基本概念

第 2 节 最速下降法

第 3 节 一维搜索

第一节 基本概念

一、非线性规划问题的数学模型

非线性规划数学模型：

$$\min f(\mathbf{x}) \quad (1)$$

$$\text{s. t. } h_i(\mathbf{x}) = 0, \quad i = 1, 2, \dots, m \quad (2)$$

$$g_j(\mathbf{x}) \geq 0, \quad j = 1, 2, \dots, l \quad (3)$$

$\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ 是 n 维欧氏空间 E^n 中的向量¹（点），而 $f(\mathbf{x})$ 、 $h_i(\mathbf{x})$ 、 $g_j(\mathbf{x})$ 至少应有一个为非线性函数。

¹ 所谓“欧氏空间”，是两点距离定义为欧几里得（Euclidean）距离（ $d = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$ ）的线性空间。

二维非线性规划问题可用作图法求解。

例，

$$\min f(\mathbf{x}) = (x_1 - 2)^2 + (x_2 - 2)^2 \quad (4)$$

$$\text{s. t. } h(\mathbf{x}) = x_1 + x_2 - 6 = 0 \quad (5)$$

满足 $f(\mathbf{x}) = C$ 的点的集合，一般为一条曲线或一张曲面，称为等值线或等值面。


$(x_1 - 2)^2 + (x_2 - 2)^2 = C$ ，是一系列以 $(2,2)^T$ 点为圆心、以 \sqrt{C} 为半径的同心圆。

等值线 $f(\mathbf{x}) = 2$ 和约束直线 AB 相切，切点 D 为最优解：

$$x_1^* = x_2^* = 3$$

最优目标值：

$$f(\mathbf{x}^*) = 2$$



若以约束

$$g(\mathbf{x}) = x_1 + x_2 - 6 \leq 0$$

代替约束（5），则最优解是 $x_1^* = x_2^* = 2$ ，即 C 点，此时 $f(\mathbf{x}^*) = 0$ 。

注 1：如果线性规划问题有最优解，则最优解只能在其可行域边界上达到（特别是在可行域的顶点达到）；

而非线性规划问题最优解（如果最优解存在）则可能在其可行域中的任意一点达到。

二、函数极值

✧ 局部极值

设 $f(\mathbf{x})$ 为定义在 n 维欧氏空间某一区域 \mathbf{R} 上的 n 元实函数。对于 $\mathbf{x}^* \in \mathbf{R}$ ，若存在某个 $\varepsilon > 0$ ，使所有与 \mathbf{x}^* 的距离小于 ε 的 $\mathbf{x} \in \mathbf{R}$ （即 $\mathbf{x} \in \mathbf{R}$ 且 $\|\mathbf{x} - \mathbf{x}^*\| < \varepsilon$ ）均满足 $f(\mathbf{x}) \geq f(\mathbf{x}^*)$ ，则称 \mathbf{x}^* 为 $f(\mathbf{x})$ 在 \mathbf{R} 上的局部极小点， $f(\mathbf{x}^*)$ 为局部极小值。

若对于所有 $\mathbf{x} \neq \mathbf{x}^*$ 且与 \mathbf{x}^* 的距离小于 ε 的 $\mathbf{x} \in \mathbf{R}$ ，严格不等式 $f(\mathbf{x}) > f(\mathbf{x}^*)$ 成立，则称 \mathbf{x}^* 为 $f(\mathbf{x})$ 在 \mathbf{R} 上的严格局部极小点， $f(\mathbf{x}^*)$ 为严格局部极小值。

✧ 全局极值

若 $\mathbf{x}^* \in \mathbf{R}$, 对于所有 $\mathbf{x} \in \mathbf{R}$ 都有 $f(\mathbf{x}) \geq f(\mathbf{x}^*)$, 则称 \mathbf{x}^* 为 $f(\mathbf{x})$ 在 \mathbf{R} 上的全局极小点, $f(\mathbf{x}^*)$ 为全局极小值。

若对于所有 $\mathbf{x} \in \mathbf{R}$ 且 $\mathbf{x} \neq \mathbf{x}^*$, 都有严格不等式 $f(\mathbf{x}) > f(\mathbf{x}^*)$ 成立, 则称 \mathbf{x}^* 为 $f(\mathbf{x})$ 在 \mathbf{R} 上的严格全局极小点, $f(\mathbf{x}^*)$ 为严格全局极小值。

✧ 极值条件

定理 1（必要条件） 设 \mathbf{R} 是 \mathbb{E}^n 上的开集，若 $f(\mathbf{x})$ 在 \mathbf{R} 上有一阶连续偏导，且 $\mathbf{x}^* \in \mathbf{R}$ 为其局部极值，则必有

$$\partial f(\mathbf{x}^*)/\partial x_1 = \cdots = \partial f(\mathbf{x}^*)/\partial x_n = 0 \quad (6)$$

即

$$\nabla f(\mathbf{x}^*) = \mathbf{0} \quad (7)$$

其中， $\nabla f(\mathbf{x}^*) = (\partial f(\mathbf{x}^*)/\partial x_1, \dots, \partial f(\mathbf{x}^*)/\partial x_n)^T$ 为函数 $f(\mathbf{x}^*)$ 在点 \mathbf{x}^* 处的梯度。

注 2: $\nabla f(\mathbf{x})$ 是 $f(\mathbf{x})$ 的等值面（等值线）在点 \mathbf{x} 处的法线方向，沿这个方向函数值增加最快。

梯度为 0 的点称为平稳点或驻点；在开集 R ，极值点必为平稳点，但平稳点不一定是极值点。

定理 2（充分条件） 设 R 是 \mathbb{E}^n 上的开集， $f(\mathbf{x})$ 在 R 上具有二阶连续偏导因而存在 Hesse 矩阵 $H(\mathbf{x})$ 。对 $\mathbf{x}^* \in R$ ，若 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ ，且对任何非零向量 $\mathbf{z} \in \mathbb{E}^n$ ，有

$$\mathbf{z}^T H(\mathbf{x}^*) \mathbf{z} > 0 \quad (8)$$

则 \mathbf{x}^* 为 $f(\mathbf{x})$ 的严格局部极小点。其中， $H(\mathbf{x}^*)$ 为 $f(\mathbf{x})$ 在点 \mathbf{x}^* 处的海赛（Hesse）矩阵。

$$\mathbf{H}(\mathbf{x}^*) = \nabla^2 f(\mathbf{x}^*)$$

$$= \begin{bmatrix} \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_1^2} & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_2 \partial x_1} & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_2^2} & \cdots & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_n \partial x_1} & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_n^2} \end{bmatrix}$$



Ludwig Otto Hesse
1811-1874, German

例，函数 $f(\mathbf{x}) = x_1^2 + 2x_2^3 + x_1x_3 + x_1x_2x_3$ ，梯度为

$$\nabla f(\mathbf{x}) = (2x_1 + x_3 + x_2x_3, 6x_2^2 + x_1x_3, x_1 + x_1x_2)^T$$

Hesse 矩阵为：

$$\mathbf{H}(\mathbf{x}) = \begin{bmatrix} 2 & x_3 & 1 + x_2 \\ x_3 & 12x_2 & x_1 \\ 1 + x_2 & x_1 & 0 \end{bmatrix}$$

定理 2 的证明需运用多元函数的一阶、二阶 Taylor 展开：

$$f(\mathbf{x}^* + \lambda \mathbf{d}) = f(\mathbf{x}^*) + \lambda \nabla f(\mathbf{x}^*)^T \mathbf{d} + o(\|\lambda \mathbf{d}\|) \quad (9)$$

以及

$$f(\mathbf{x}^* + \lambda \mathbf{d}) = f(\mathbf{x}^*) + \lambda \nabla f(\mathbf{x}^*)^T \mathbf{d} + \frac{1}{2} \lambda^2 \mathbf{d}^T \nabla^2 f(\mathbf{x}^*) \mathbf{d} + o(\|\lambda \mathbf{d}\|^2) \quad (10)$$

证明：略。

定理 2 的条件 (8) 式： $\mathbf{z}^T \mathbf{H}(\mathbf{x}^*) \mathbf{z} > 0$ ，意思是海塞矩阵 $\mathbf{H}(\mathbf{x}^*)$ 在 \mathbf{x}^* 处为正定矩阵。

✧ 正定矩阵

矩阵 $A \in \mathbb{R}^{n \times n}$ 为对称矩阵，若对任意向量 $d \in \mathbb{R}^n$ ，有

$$d^T A d \geq 0$$

则称 A 为半正定矩阵；若对 $d \neq 0$ 有严格不等式成立：

$$d^T A d > 0, d \neq 0$$

则称 A 为正定矩阵。

若对任意向量 $d \in \mathbb{R}^n$ ，有： $d^T A d \leq 0$ ，则称 A 为半负定矩阵；若对任意 $d \neq 0$ 有严格不等式成立： $d^T A d < 0$ ，则称 A 为负定矩阵。

✓ 如何判断矩阵正定或负定——各阶主子式

矩阵各阶主子式，是指各阶左上角元素构成的行列式：

一阶正；二阶正；三阶正；四阶正；五阶正

$$\begin{bmatrix} \underline{a_{11}} & a_{12} & a_{13} & a_{14} & a_{15} \\ a_{21} & a_{22} & a_{23} & a_{24} & a_{25} \\ a_{31} & a_{32} & a_{33} & a_{34} & a_{35} \\ a_{41} & a_{42} & a_{43} & a_{44} & a_{45} \\ a_{51} & a_{52} & a_{53} & a_{54} & a_{55} \end{bmatrix}$$

如果各阶主子式严格大于零，则矩阵正定。

$$\text{例, } A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 4 \end{bmatrix}$$

$$|1| = 1 > 0, \quad \begin{vmatrix} 1 & 1 \\ 1 & 2 \end{vmatrix} = 1 > 0, \quad \begin{vmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 4 \end{vmatrix} = 3 > 0$$

因此A是正定矩阵。

注意，各阶主子式严格大于零（ > 0 ），则矩阵正定；
但若有某阶主子式 $= 0$ （ ≥ 0 ），则不能保证半正定。

例，

矩阵， $\mathbf{A} = \begin{bmatrix} 1 & 1 & -3 \\ 1 & 1 & -3 \\ -3 & -3 & 5 \end{bmatrix}$ ，一阶主子式 > 0 ，二阶、三

阶 $= 0$ ，但它并不是半正定的——因为存在向量：

$$(1,1,1) \begin{bmatrix} 1 & 1 & -3 \\ 1 & 1 & -3 \\ -3 & -3 & 5 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = -3 < 0。$$

因此，从主子式 ≥ 0 ，不能推出矩阵半正定；只能从各阶主子式 > 0 ，推出矩阵正定

若各阶主子式负 (< 0)、正 (> 0) 相间 (奇负偶正),
则矩阵负定。

一阶负;二阶正;三阶负;四阶正;五阶负

$$\begin{bmatrix} \underline{a_{11}} & a_{12} & a_{13} & a_{14} & a_{15} \\ a_{21} & a_{22} & a_{23} & a_{24} & a_{25} \\ a_{31} & a_{32} & a_{33} & a_{34} & a_{35} \\ a_{41} & a_{42} & a_{43} & a_{44} & a_{45} \\ a_{51} & a_{52} & a_{53} & a_{54} & a_{55} \end{bmatrix}$$

例, $A = \begin{bmatrix} -2 & 2 & 0 \\ 2 & -3 & -1 \\ 0 & -1 & -5 \end{bmatrix}$, 一阶: $|-2| = -2 < 0$,

二阶: $\begin{vmatrix} -2 & 2 \\ 2 & -3 \end{vmatrix} = 2 > 0$, 三阶: $\begin{vmatrix} -2 & 2 & 0 \\ 2 & -3 & -1 \\ 0 & -1 & -5 \end{vmatrix} = -8 < 0$,

因此矩阵A负定。

与半正定情况相同, 如果某阶主子式=0, 就无法从主子式的值判断半负定。

例, $A = \begin{bmatrix} -1 & -1 & 3 \\ -1 & -1 & 3 \\ 3 & 3 & -5 \end{bmatrix}$

一阶 < 0 、二阶、三阶 $= 0$ 。但是存在向量 $(1,1,1)^T$, 有:

$$(1,1,1) \begin{bmatrix} -1 & -1 & 3 \\ -1 & -1 & 3 \\ 3 & 3 & -5 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = 3 > 0$$

因此, 矩阵A不是 (半) 负定的。

✓ 求高阶行列式的值——右上三角阵

以高斯消元将行列式化为右上三角形式，则对角线元素的乘积就是行列式的值。

$$\begin{vmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 4 \end{vmatrix} = \begin{vmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & 4 \end{vmatrix} = \begin{vmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 3 \end{vmatrix} = 3$$

$$\begin{vmatrix} 1 & 1 & 2 & 4 \\ 1 & 2 & 1 & 1 \\ 1 & 2 & 4 & -1 \\ -1 & 2 & 3 & 1 \end{vmatrix} = \begin{vmatrix} 1 & 1 & 2 & 4 \\ 0 & 1 & -1 & -3 \\ 0 & 0 & 3 & -2 \\ 0 & 0 & 0 & 58/3 \end{vmatrix} = 58$$

注 3: **定理 2** 中的充分条件 (8) 并不是必要条件, 即: 极小点处的 Hesse 矩阵并不一定正定。


$$f(x) = x^4, \text{ 极小点 } x^* = 0, \text{ 但 } \nabla^2 f(x^*) = 0.$$

注 4: **定理 2** 中 (8) 式要成为充分条件, 必须是**严格不等式**成立 (正定)。


$f(x) = x^3$, 在 $x = 0$ 处, $\nabla^2 f(x) = 0$ 且 $\nabla^2 f(x) = 0$ (半正定), 但 $x = 0$ 并不是极值点, 只是个平稳点。

而 $f(x) = x^3/3 - x$ 在 $x = 1$ 处满足定理 2 ($\nabla^2 f(x) = 2 > 0$), 是极小点。


$$f(x) = x^4$$



$$f(x) = x^3$$



$$f(x) = x^3/3 - x$$



三、凸函数与凸规划

✧ 凸函数的定义

设 $f(\mathbf{x})$ 为 n 维欧氏空间 \mathbb{E}^n 中某个凸集 \mathbf{R} 上的函数, 若对任何实数 $\alpha \in (0,1)$, 以及 $\mathbf{x}^{(1)}, \mathbf{x}^{(2)} \in \mathbf{R}$, 恒有

$$f(\alpha \mathbf{x}^{(1)} + (1 - \alpha) \mathbf{x}^{(2)}) \leq \alpha f(\mathbf{x}^{(1)}) + (1 - \alpha) f(\mathbf{x}^{(2)})$$

则称 $f(\mathbf{x})$ 为定义在 \mathbf{R} 上的凸函数。



若恒有严格不等式成立:

$$f(\alpha \mathbf{x}^{(1)} + (1 - \alpha) \mathbf{x}^{(2)}) < \alpha f(\mathbf{x}^{(1)}) + (1 - \alpha) f(\mathbf{x}^{(2)})$$

则称 $f(\mathbf{x})$ 为定义在 \mathbf{R} 上的严格凸函数。

若函数 $f(x)$ 是凸函数（严格凸函数），则 $-f(x)$ 是凹函数（严格凹函数）。

凸/凹函数的几何意义：凸函数上任意两点的连线在函数上方；凹函数上任意两点的连线在函数下方。



线性函数既可看作凸函数，也可看作凹函数。

✧ 凸函数的性质

性质 1: 设 $f(\mathbf{x})$ 为定义在凸集 \mathbf{R} 上的凸函数, 则对任意实数 $\beta \geq 0$, 函数 $\beta f(\mathbf{x})$ 也是定义在 \mathbf{R} 上的凸函数。

性质 2: 设 $f_1(\mathbf{x})$ 和 $f_2(\mathbf{x})$ 为定义在凸集 \mathbf{R} 上的两个凸函数, 则 $f(\mathbf{x}) = f_1(\mathbf{x}) + f_2(\mathbf{x})$ 仍为定义在 \mathbf{R} 上的凸函数。

性质 3: 设 $f(\mathbf{x})$ 为定义在凸集 \mathbf{R} 上的凸函数, 则对任一实数 β , 集合 $\mathbf{S}_\beta = \{\mathbf{x} | \mathbf{x} \in \mathbf{R}, f(\mathbf{x}) \leq \beta\}$ 是凸集 (\mathbf{S}_β 称为水平集/截集)。

✧ 凸函数的判定


可直接依据凸函数的定义判断是否为凸函数；对于可微函数，可利用下述判别定理。

定理 3（一阶条件） 设 R 为 n 维欧氏空间 E^n 的**开凸集**， $f(\mathbf{x})$ 在 R 上具有一阶连续偏导，则 $f(\mathbf{x})$ 为 R 上的凸函数的**充要条件**是，对任意不同两点 $\mathbf{x}^{(1)} \neq \mathbf{x}^{(2)} \in R$ ，恒有

$$f(\mathbf{x}^{(2)}) \geq f(\mathbf{x}^{(1)}) + \nabla f(\mathbf{x}^{(1)})^T (\mathbf{x}^{(2)} - \mathbf{x}^{(1)})$$

若上式为**严格**不等式，就是**严格凸函数**的充要条件。

定理 3 表明，凸函数上某点发出的切线，总是**不高于**该凸函数——凸函数的切线总是位于函数下方。



定理 4 (**二阶条件**) 设 R 为 n 维欧氏空间 \mathbb{E}^n 上的**开凸集**， $f(\mathbf{x})$ 在 R 上具有二阶连续偏导数，则 $f(\mathbf{x})$ 为 R 上的**凸函数**的**充要条件**是： $f(\mathbf{x})$ 的**海赛矩阵** $H(\mathbf{x})$ 在 R 上**处处**半正定。²

如果**处处**正定，则是**严格**凸函数。

² 仅在某个点处半正定，则在再该点周围，函数不一定具有凸性，如 $f(x) = x^3$ 在 $x = 0$ 附近。

凹函数：如果函数 $f(\mathbf{x})$ 在**开凸集** R 上的海赛矩阵处处半负定，则函数是凹函数；

如果函数的海森矩阵**负定**（**奇数阶主子式严格小于零，偶数阶严格大于零**），则函数是严格凹函数。

若 Hesse 矩阵**不定**，则函数在所定义的集合上不具有一致的凹性或凸性（在有些区域凹，有些区域凸）。

判断下面各函数是凹函数还是凸函数：

$$f(\mathbf{x}) = e^{x_1+x_2} + x_3^2$$

$$f(\mathbf{x}) = x_1^2 + x_2^2 + x_1x_2$$

$$f(\mathbf{x}) = -x_1^2 - x_2^2 + x_1x_2$$

$$f(\mathbf{x}) = x_1^2 + x_2^2 + 3x_1x_2$$

$$f(\mathbf{x}) = -x_1^2 - x_2^2 - 3x_1x_2$$

$$f(\mathbf{x}) = x_1^2 + x_2^2 + x_3^4$$

$$f(\mathbf{x}) = -x_1^2 - x_2^2 - x_3^4 + x_4^2 + x_1x_2$$

✧ 凸函数的极值

函数局部极小并不一定是其全局最小（全局极小值）。
但对定义在凸集上的凸函数，其极小值就是全局最小。



定理 5 若 $f(\mathbf{x})$ 是凸集 \mathbf{R} 上的凸函数，则其任一极小点就是它在 \mathbf{R} 上的最小点，且极小点形成一个凸集。

定理 6 设 $f(\mathbf{x})$ 是定义在凸集 \mathbf{R} 上的可微凸函数，若存在点 $\mathbf{x}^* \in \mathbf{R}$ ，使得对于所有 $\mathbf{x} \in \mathbf{R}$ ，有

$$\nabla f(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) \geq 0$$

则 \mathbf{x}^* 是 $f(\mathbf{x})$ 在 \mathbf{R} 上的最小点（全局极小点）。

注 4: **定理 5 和 6** 说明, 定义在凸集上的凸函数的**平稳点**, 就是其**全局极小点**。**全局极小点**并不一定是唯一的, 但若为**严格凸函数**, 则**全局极小点**就是**唯一的**。



✧ 凸规划

考虑集合： $\mathbf{R} = \{\mathbf{x} | g_j(\mathbf{x}) \geq 0, j = 1, 2, \dots, l\}$ 。如果 $g_j(\mathbf{x})$ 为凹函数，或者 $-g_j(\mathbf{x})$ 为凸函数，那么根据前述性质 3，集合 $\mathbf{R} = \{\mathbf{x} | g_j(\mathbf{x}) \geq 0, j = 1, 2, \dots, l\}$ 是凸集。

凸规划就是在凸集上最小化一个凸函数，即

$$\begin{aligned} & \min_{\mathbf{x} \in \mathbf{R}} f(\mathbf{x}) \\ & \text{s. t. } \mathbf{R} = \{\mathbf{x} | g_j(\mathbf{x}) \geq 0, j = 1, 2, \dots, l\} \end{aligned}$$

若 $f(\mathbf{x})$ 为凸函数， $g_j(\mathbf{x}), (j = 1, 2, \dots, l)$ 为凹函数（或 $-g_j(\mathbf{x})$ 为凸函数），这样的非线性规划称为凸规划。


注 5: 凸规划可行域为凸集, 局部最优解即为全局最优解; 若有多个最优解, 则最优解的集合仍然形成一个凸集。

当凸规划的目标函数为严格凸函数时, 若最优解存在, 则最优解必定唯一。

由于线性函数既可视作凸函数, 又可视作凹函数, 故线性规划也属于一种凸规划。

例 1, 非线性规划问题

$$\begin{aligned} \min f(\mathbf{x}) &= x_1^2 + x_2^2 - 4x_1 + 4 \\ \begin{cases} g_1(\mathbf{x}) = x_1 - x_2 + 2 \geq 0 \\ g_2(\mathbf{x}) = -x_1^2 + x_2 - 1 \geq 0 \\ x_1, x_2 \geq 0 \end{cases} \end{aligned}$$



目标函数 $f(\mathbf{x})$ 严格凸, $g_2(\mathbf{x})$ 凹, 其它约束均为线性函数, 所以是凸规划问题。

图解可知, C 为最优解:

$$\mathbf{x}^* = (0.58, 1.34)^T$$

最优值:

$$f(\mathbf{x}^*) = 3.8$$

四、下降迭代算法

对一般的无约束 n 元函数 $f(\mathbf{x})$ ，由梯度条件 $\nabla f(\mathbf{x}) = \mathbf{0}$ 求最优解，得到的是一个非线性方程组，求解可能相当困难。若函数不可微，则更无法使用这种方法。

迭代法：先给定初始估计 $\mathbf{x}^{(0)}$ ，然后按某种规则（称为算法）找出比 $\mathbf{x}^{(0)}$ 更好的解 $\mathbf{x}^{(1)}$ （对极小化问题，即要求满足 $f(\mathbf{x}^{(1)}) < f(\mathbf{x}^{(0)})$ ），再按此算法找出比 $\mathbf{x}^{(1)}$ 更好的解 $\mathbf{x}^{(2)}$ ，...，如此得到一个解序列 $\{\mathbf{x}^{(k)}\}$ 。

若该解序列存在极限 \mathbf{x}^* ，即 $\lim_{k \rightarrow \infty} \|\mathbf{x}^{(k)} - \mathbf{x}^*\| = 0$ ，则称它收敛于 \mathbf{x}^* 。

所产生的解序列 $\{\mathbf{x}^{(k)}\}$ 使目标函数值逐步减少的迭代算法称为下降迭代算法。


假定已迭代到点 $\mathbf{x}^{(k)}$ ，若从 $\mathbf{x}^{(k)}$ 出发沿任何方向移动都不能使目标值下降，则 $\mathbf{x}^{(k)}$ 就是局部极小，迭代停止。

若至少存在一个方向 $\mathbf{p}^{(k)}$ 使目标函数值有所下降，则可选定该下降方向 $\mathbf{p}^{(k)}$ ，沿该方向适当前进一步，使 $f(\mathbf{x}^{(k+1)}) < f(\mathbf{x}^{(k)})$ ，就得到下一迭代点 $\mathbf{x}^{(k+1)}$ 。

这相当于在射线 $\mathbf{x} = \mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)}$ 上选定新点

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)}$$

$\mathbf{p}^{(k)}$ 称为搜索方向， λ_k 称为步长或步长因子。



✧ 下降迭代算法

- (1) 选定某一初始点 $\mathbf{x}^{(0)}$ ，令 $k = 0$ ；
- (2) 假设迭代到第 k 步，则确定一个搜索方向 $\mathbf{p}^{(k)}$ ；
- (3) 从 $\mathbf{x}^{(k)}$ 出发沿 $\mathbf{p}^{(k)}$ 求步长 λ_k ，产生下一个迭代点 $\mathbf{x}^{(k+1)}$ ；
- (4) 检查新点 $\mathbf{x}^{(k+1)}$ 是否为极小点或近似极小。若是，则停止迭代。否则，令 $k = k + 1$ ，转(2)继续迭代。

注 6：选取搜索方向 $\mathbf{p}^{(k)}$ 是关键步骤，各种下降迭代算法的区分，主要就在于确定搜索方向的方法不同。

✧ 步长的确定方法

(1) 最简单方法：令它等于某一常数（如 $\lambda_k = 1$ ），但这不能保证目标函数值一定下降。

(2) 可接受点法：任选使目标值下降的步长 λ_k 。

(3) 一维搜索法：沿搜索方向使目标值下降最多，即沿射线 $\mathbf{x} = \mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)}$ ，求目标函数的极小值：

$$\lambda_k: \min_{\lambda} f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})$$

求关于 λ 的一元函数 $f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})$ 的极小点 λ_k ，称为一维搜索或线搜索，所确定的步长 λ_k 称为最佳步长。


☆ 一维搜索的重要性质

定理 7 设函数 $f(\mathbf{x})$ 具有一阶连续偏导，迭代点 $\mathbf{x}^{(k+1)}$ 按下述规则产生

$$\begin{cases} \lambda_k: \min_{\lambda} f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)}) \\ \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)} \end{cases}$$

则有： $\nabla f(\mathbf{x}^{(k+1)})^T \mathbf{p}^{(k)} = 0$ 。

定理 7 表明，在搜索方向上得到的最优点处的梯度和该搜索方向正交。



✧ 迭代终止准则（收敛准则）

真正的最优解事先并不知道，何时停止迭代，可根据相继两次迭代的结果判断。常用的终止准则有：

(1) 相继两次迭代的绝对误差足够小

$$\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\| < \varepsilon_1 \text{ or } |f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^{(k)})| < \varepsilon_2$$

(2) 相继两次迭代的相对误差足够小

$$\frac{\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\|}{\|\mathbf{x}^{(k)}\|} < \varepsilon_3 \text{ or } \frac{|f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^{(k)})|}{|f(\mathbf{x}^{(k)})|} < \varepsilon_4$$

(3) 目标函数梯度的模足够小： $\|\nabla f(\mathbf{x}^{(k)})\| < \varepsilon_5$ 。

第二节 最速下降法


◇ 基本原理

考虑无约束优化问题

$$\min f(\mathbf{x}), \mathbf{x} \in \mathbb{E}^n$$

下降迭代算法：从某一点出发，选择一个使目标函数值下降的方向前进，就可以优化目标函数。

下降方向有很多，选择哪一个？



1847 年，法国数学家 Cauchy（柯西）提出使用 目标函数的负梯度 作为 下降方向：

$$\mathbf{p} = -\nabla f(\mathbf{x})$$

负梯度方向是函数在 **当前点** 下降最快的方向，因此基于负梯度的下降迭代算法称为 最速下降法。



Augustin-Louis Cauchy

1798-1857, French

☆ 最速下降法的迭代公式

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)} = \mathbf{x}^{(k)} - \lambda_k \nabla f(\mathbf{x}^{(k)})$$

λ_k 为迭代步长，满足：

$$f(\mathbf{x}^{(k)} - \lambda_k \nabla f(\mathbf{x}^{(k)})) = \min_{\lambda \geq 0} f(\mathbf{x}^{(k)} - \lambda \nabla f(\mathbf{x}^{(k)}))$$

这是函数 $f(\mathbf{x}^{(k)} - \lambda \nabla f(\mathbf{x}^{(k)}))$ 关于单变量 λ 的优化问题。

若函数关于 λ 凸，且一阶条件可解，则容易获得最优 λ 从而实现最优下降，否则就要使用数值型一维搜索（线搜索）来求 λ 的近似最优值。

☆ 最速下降法计算步骤

(1) 给定初点 $\mathbf{x}^{(0)} \in \mathbb{E}^n$, 允许误差 $\varepsilon > 0$, 置 $k = 0$ 。

(2) 设迭代到第 k 步, 令搜索方向 $\mathbf{p}^{(k)} = -\nabla f(\mathbf{x}^{(k)})$ 。

(3) 若 $\|\mathbf{p}^{(k)}\| \leq \varepsilon$, 则停止计算; 否则, 从 $\mathbf{x}^{(k)}$ 出发, 沿 $\mathbf{p}^{(k)}$ 进行一维搜索, 求 λ_k , 使

$$f(\mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)}) = \min_{\lambda \geq 0} f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})$$

(4) 令 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)}$, 置 $k := k + 1$, 转 (2)。

例 3, 求 $f(\mathbf{x}) = 2x_1^2 + x_2^2$ 的最小点。其中初始点: $\mathbf{x}^{(0)} = (1,1)^T$, 精度要求 $\|\nabla f(\mathbf{x})\| \leq \varepsilon = 1/10$ 。

第 1 次迭代: 目标函数**梯度** $\nabla f(\mathbf{x}) = \begin{bmatrix} 4x_1 \\ 2x_2 \end{bmatrix}$, 令**搜索方向**

$$\mathbf{p}^{(0)} = -\nabla f(\mathbf{x}^{(0)}) = \begin{bmatrix} -4 \\ -2 \end{bmatrix}, \text{ 有}$$

$$\|\mathbf{p}^{(0)}\| = \sqrt{14 + 4} = 2\sqrt{5} > \varepsilon$$

不满足精度要求。

从 $\mathbf{x}^{(0)}$ 出发, 令 $\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \lambda \mathbf{p}^{(0)} = \begin{bmatrix} 1 - 4\lambda \\ 1 - 2\lambda \end{bmatrix}$, 沿方向 $\mathbf{p}^{(0)}$

进行**一维搜索**, 求最优步长 λ_0 , 即

$$\min_{\lambda \geq 0} \phi(\lambda) = f(\mathbf{x}^{(0)} + \lambda \mathbf{p}^{(0)}) = 2(1 - 4\lambda)^2 + (1 - 2\lambda)^2$$

$\phi(\lambda)$ 关于 λ 凸，运用一阶条件，令 $\phi'(\lambda) = 0$ ，解得：

$$\lambda_0 = 5/18$$

因此沿搜索方向 $\mathbf{p}^{(0)}$ ，得到极小点为：

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \lambda_0 \mathbf{p}^{(0)} = \begin{bmatrix} -1/9 \\ 4/9 \end{bmatrix}$$

$$\mathbf{p}^{(1)} = -\nabla f(\mathbf{x}^{(1)}) = \begin{bmatrix} 4/9 \\ -8/9 \end{bmatrix}, \quad \|\mathbf{p}^{(1)}\| = 4\sqrt{5}/9 \approx 0.99 > \varepsilon$$

不满足精度要求，需要进一步迭代。

第 2 次迭代:

$$\min_{\lambda \geq 0} \phi(\lambda) = f(\mathbf{x}^{(1)} + \lambda \mathbf{p}^{(1)}) = 2\left(-\frac{1}{9} + \frac{4}{9}\lambda\right)^2 + \left(\frac{4}{9} - \frac{8}{9}\lambda\right)^2$$

解得:

$$\lambda_1 = 5/12, \quad \mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \lambda_1 \mathbf{p}^{(1)} = \begin{bmatrix} 2/27 \\ 2/27 \end{bmatrix}$$

$$\mathbf{p}^{(2)} = -\nabla f(\mathbf{x}^{(2)}) = \begin{bmatrix} -8/27 \\ -4/27 \end{bmatrix}$$

$$\|\mathbf{p}^{(2)}\| = 4\sqrt{5}/27 \approx 0.33 > \varepsilon$$

仍然不满足精度要求。

第 3 次迭代:

$$\min_{\lambda \geq 0} \phi(\lambda) = f(\mathbf{x}^{(2)} + \lambda \mathbf{p}^{(2)}) = \frac{8}{27^2} (1 - 4\lambda)^2 + \frac{4}{27^2} (1 - 2\lambda)^2$$

解得:

$$\lambda_2 = 5/18, \quad \mathbf{x}^{(3)} = \mathbf{x}^{(2)} + \lambda_2 \mathbf{p}^{(2)} = \frac{2}{243} \begin{bmatrix} -1 \\ 4 \end{bmatrix}$$

$$\nabla f(\mathbf{x}^{(3)}) = \frac{2}{243} \begin{bmatrix} -4 \\ 8 \end{bmatrix}$$

此时有, $\|\nabla f(\mathbf{x}^{(3)})\| = \frac{8}{243} \sqrt{5} \approx 0.07 < \varepsilon$, 满足精度要求, 得

到近似最优解:

$$\mathbf{x}^* = \frac{2}{243} \begin{bmatrix} -1 \\ 4 \end{bmatrix}.$$

✧ 单变量问题的优化

下降迭代算法每一步都需要求解一个单变量问题，若难以用微分方法求最优步长 λ_k ，则需考虑近似方法。

方法 1：近似最佳步长

若 $f(\mathbf{x})$ 具有二阶连续偏导，则可以在点 $\mathbf{x}^{(k)}$ 处用二阶泰勒展开近似函数 $f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})$ ：

$$\begin{aligned} f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)}) &= f(\mathbf{x}^{(k)} - \lambda \nabla f(\mathbf{x}^{(k)})) \approx \\ &f(\mathbf{x}^{(k)}) - \lambda \nabla f(\mathbf{x}^{(k)})^T \nabla f(\mathbf{x}^{(k)}) + \frac{1}{2} \lambda^2 \nabla f(\mathbf{x}^{(k)})^T \mathbf{H}(\mathbf{x}^{(k)}) \nabla f(\mathbf{x}^{(k)}) \end{aligned}$$

其中 $\mathbf{H}(\mathbf{x}^{(k)}) = \nabla^2 f(\mathbf{x}^{(k)})$ 是函数在 $\mathbf{x}^{(k)}$ 处的海塞矩阵。

对 λ 求导并令导数等于零，可得近似最佳步长：

$$\lambda_k = \frac{\nabla f(\mathbf{x}^{(k)})^T \nabla f(\mathbf{x}^{(k)})}{\nabla f(\mathbf{x}^{(k)})^T \mathbf{H}(\mathbf{x}^{(k)}) \nabla f(\mathbf{x}^{(k)})} \quad (11)$$

下一迭代点： $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)}$

有时将搜索方向 $\mathbf{p}^{(k)}$ 的模规格化为 1，此时

$$\mathbf{p}^{(k)} = -\frac{\nabla f(\mathbf{x}^{(k)})}{\|\nabla f(\mathbf{x}^{(k)})\|} \quad (12)$$

那么，式（11）相应变为

$$\lambda_k = \frac{\nabla f(\mathbf{x}^{(k)})^T \nabla f(\mathbf{x}^{(k)}) \|\nabla f(\mathbf{x}^{(k)})\|}{\nabla f(\mathbf{x}^{(k)})^T \mathbf{H}(\mathbf{x}^{(k)}) \nabla f(\mathbf{x}^{(k)})} \quad (13)$$

例 4，从 $\mathbf{x}^{(0)} = (0.5, 0.8)^T$ 出发，使用近似最佳步长，以最速下降法求 $f(\mathbf{x}) = 4x_1^2 + 4x_2^2 + e^{x_1+x_2}$ 的极小点。

解，梯度和 Hesse 矩阵为：

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 8x_1 + e^{x_1+x_2} \\ 8x_2 + e^{x_1+x_2} \end{bmatrix}, \quad \mathbf{H}(\mathbf{x}) = \begin{bmatrix} 8 + e^{x_1+x_2} & e^{x_1+x_2} \\ e^{x_1+x_2} & 8 + e^{x_1+x_2} \end{bmatrix}$$

使用规格化搜索方向： $\mathbf{p}^{(k)} = -\nabla f(\mathbf{x}^{(k)}) / \|\nabla f(\mathbf{x}^{(k)})\|$ 。

在初始点 $\mathbf{x}^{(0)} = (0.5, 0.8)^T$ ，梯度和 Hesse 矩阵为：

$$\nabla f(\mathbf{x}^{(0)}) = (7.6693, 10.0693)^T, \quad \mathbf{H}(\mathbf{x}^{(0)}) = \begin{bmatrix} 11.67 & 3.67 \\ 3.67 & 11.67 \end{bmatrix}$$

步长：


$$\lambda_0 = \frac{\nabla f(\mathbf{x}^{(0)})^T \nabla f(\mathbf{x}^{(0)}) \|\nabla f(\mathbf{x}^{(0)})\|}{\nabla f(\mathbf{x}^{(0)})^T \mathbf{H}(\mathbf{x}^{(0)}) \nabla f(\mathbf{x}^{(0)})} = 0.8324$$

搜索方向: $\mathbf{p}^{(0)} = -\frac{\nabla f(\mathbf{x}^{(0)})}{\|\nabla f(\mathbf{x}^{(0)})\|} = -(0.6059, 0.7955)^T$

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \lambda_0 \mathbf{p}^{(0)} = (-0.0043, 0.1378)^T$$

在 $\mathbf{x}^{(1)}$ 点计算梯度、Hesse 矩阵和步长, 迭代如下:

迭代点	$\nabla f(\mathbf{x}^{(k)})$	$\mathbf{H}(\mathbf{x}^{(k)})$	λ_k	$f(\mathbf{x}^{(k)})$
$\mathbf{x}^{(0)} = (0.5000, 0.8000)^T$	$(7.67, 10.07)^T$	$\begin{bmatrix} 11.67 & 3.67 \\ 3.67 & 11.67 \end{bmatrix}$	0.8324	7.2293
$\mathbf{x}^{(1)} = (-0.0043, 0.1378)^T$	$(1.11, 2.25)^T$	$\begin{bmatrix} 9.14 & 1.14 \\ 1.14 & 9.147 \end{bmatrix}$	0.2492	1.2189
$\mathbf{x}^{(2)} = (-0.1146, -0.0856)^T$	$(-0.10, 0.13)^T$	$\begin{bmatrix} 8.82 & 0.82 \\ 0.82 & 8.82 \end{bmatrix}$	0.0206	0.9004
$\mathbf{x}^{(3)} = (-0.1024, -0.1022)^T$	$(0.00, 0.00)^T$	$\begin{bmatrix} 8.81 & 0.81 \\ 0.81 & 8.81 \end{bmatrix}$	0.0005	0.8987
$\mathbf{x}^{(4)} = (-0.1020, -0.1019)^T$	$(0.00, 0.00)^T$	$\begin{bmatrix} 8.82 & 0.82 \\ 0.82 & 8.82 \end{bmatrix}$	≈ 0	0.8987
$\mathbf{x}^{(5)} = (-0.1019, -0.1019)^T$	$(0.00, 0.00)^T$	$\begin{bmatrix} 8.82 & 0.82 \\ 0.82 & 8.82 \end{bmatrix}$	≈ 0	0.8987
$\mathbf{x}^{(6)} = (-0.1019, -0.1019)^T$	$(0.00, 0.00)^T$	$\begin{bmatrix} 8.82 & 0.82 \\ 0.82 & 8.82 \end{bmatrix}$	≈ 0	0.8987



$$f(\mathbf{x}) = 4x_1^2 + 4x_2^2 + e^{x_1+x_2}$$




注 8：负梯度方向，仅在当前点附近才具有“**最速下降**”性，

对于整个极小化过程来说，负梯度并非**收敛最快**的方向。

从全局看，精确一维搜索得到的前后两次迭代方向相互垂直，因而搜索路线总体呈**锯齿**状，当趋近极小点时，即使向极小点移动很小距离，由于

锯齿现象，也要经历不小的弯路，**收敛速度**大为减慢。³



³ 如例 3: $\mathbf{p}^{(0)} = \begin{bmatrix} -4 \\ -2 \end{bmatrix}$; $\mathbf{p}^{(1)} = \begin{bmatrix} 4/9 \\ -8/9 \end{bmatrix}$; $\mathbf{p}^{(2)} = \begin{bmatrix} -8/27 \\ -4/27 \end{bmatrix}$; $\mathbf{p}^{(3)} = -\nabla f(\mathbf{x}^{(3)}) = \frac{2}{243} \begin{bmatrix} 4 \\ -8 \end{bmatrix}$, 相邻点积均为 0——垂直。

在实用中，常将最速下降法和其它方法联合起来应用，在前期使用最速下降法，而在接近极小点时，则使用收敛较快的其它方法。

无约束优化更好的求解方法有：

- (1) 牛顿法
- (2) 共轭梯度法
- (3) 拟牛顿法（变尺度法）

方法 2：数值型一维搜索

求近似最佳步长，除了需要使用梯度，还需要使用 **Hesse 矩阵**，对高阶问题，计算起来比较麻烦；

而函数的二次近似也有可能因为步长不精确而导致不收敛，结果在最优点附近震荡；

在实际计算中，可使用数值型**一维搜索**技术（**0.618 法**、**斐波那契法**等）确定迭代步长。

第三节 一维搜索

所谓一维搜索，就是求解单变量（一维）函数最优值的一类数值方法，在下降迭代算法⁴中经常碰到。

考虑以最速下降法求解：

$$\min f(\mathbf{x}) = 4x_1^2 + 4x_2^2 + e^{x_1+x_2}$$

假设迭代到点 $\mathbf{x}^{(k)} = (0.5, 0.8)^T$ ，那么规格化下降方向为：

$$\mathbf{p}^{(k)} = -\frac{\nabla f(\mathbf{x}^{(k)})}{\|\nabla f(\mathbf{x}^{(k)})\|} = -(0.6059, 0.7955)^T$$

下一步迭代点为：

⁴ 下降迭代算法需不断求解关于步长的单变量问题： $\min_{\lambda \geq 0} f(\mathbf{x}^{(k+1)}) = f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})$ 。

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)} = (0.5 - 0.6059\lambda, 0.8 - 0.7955\lambda)^T$$

于是需要求解如下问题：

$$\min \phi(\lambda) = 4(0.5 - 0.6059\lambda)^2 + 4(0.8 - 0.7955\lambda)^2 + e^{1.3 - 1.4014\lambda}$$

使用一阶条件求解，并不容易。

若在点 $\mathbf{x}^{(k)}$ 对原函数做二阶近似，则可得到近似最佳步长——但要使用 Hesse 矩阵，高阶问题计算较麻烦。

若原问题性质较好，则所碰到的上述单变量问题的目标函数，都是所谓单峰函数，可以考虑使用一维搜索方法进行数值求解。


一、单峰函数及其性质

定义 1 设 $f(x)$ 是定义在闭区间 $[a, b]$ 上的一元实函数, \bar{x} 是 $f(x)$ 在 $[a, b]$ 上的极小点。

若对任意 $x^{(1)} < x^{(2)} \in [a, b]$, 成立:

$$\begin{cases} f(x^{(1)}) > f(x^{(2)}) & \text{if } x^{(2)} \leq \bar{x} \\ f(x^{(1)}) < f(x^{(2)}) & \text{if } \bar{x} \leq x^{(1)} \end{cases}$$

则称函数 f 是闭区间 $[a, b]$ 上的**单峰函数**。




✧ 单峰函数的性质

通过计算区间 $[a, b]$ 内两个不同点处的函数值，就能确定一个包含极小点的子区间。


定理 8 设 $f(x)$ 是区间 $[a, b]$ 上的单峰函数， $x^{(1)}, x^{(2)} \in [a, b]$ ，且 $x^{(1)} < x^{(2)}$ 。如果 $f(x^{(1)}) > f(x^{(2)})$ ，则对每一个 $x \in [a, x^{(1)}]$ ，必有 $f(x) > f(x^{(2)})$ ；如果 $f(x^{(1)}) \leq f(x^{(2)})$ ，则对每一个 $x \in [x^{(2)}, b]$ ，必有 $f(x) \geq f(x^{(1)})$ 。

根据**定理 8**，如果 $f(x^{(1)}) > f(x^{(2)})$ ，则意味着最小点不可能在区间 $[a, x^{(1)}]$ 内，那么只能在 $[x^{(1)}, b]$ 内：

情况1




情况2




反过来, 若 $f(x^{(1)}) \leq f(x^{(2)})$, 则最小点不可能在区间 $[x^{(2)}, b]$ 内, 只能在 $[a, x^{(2)}]$ 内。

情况1



情况2



所以, 只需选择两个试探点, 就可将包含极小点的区间缩短为 $[x^{(1)}, b]$, 或 $[a, x^{(2)}]$ 。

二、0.618 法（黄金分割法）

基本思想



不断取试探点可使包含极小点的区间不断缩短，直到满足精度要求；取试探点的方案很多，0.618 法的基本思路是：每次都取黄金分割点作为试探点。

试探点计算公式

设 $f(x)$ 是 $[a_1, b_1]$ 上的单峰函数，极小点 $\bar{x} \in [a_1, b_1]$ 。设进行第 k 次迭代时，有 $\bar{x} \in [a_k, b_k]$ 。为缩短包含极小点的区间，取两个试探点 $\lambda_k < \mu_k \in [a_k, b_k]$ ，如下：

$$\lambda_k = a_k + 0.382(b_k - a_k) \quad (14)$$

$$\mu_k = a_k + 0.618(b_k - a_k) \quad (15)$$



计算步骤:

(1) 置初始区间 $[a_1, b_1]$ 及精度要求 $L > 0$, 计算试探点 λ_1 和 μ_1 , 令 $k = 1$, 计算函数值 $f(\lambda_1)$ 和 $f(\mu_1)$, 其中

$$\lambda_1 = a_1 + 0.382(b_1 - a_1), \quad \mu_1 = a_1 + 0.618(b_1 - a_1)$$

(2) 若 $b_k - a_k < L$, 则停止计算。否则, 当 $f(\lambda_k) > f(\mu_k)$ 时, 转步骤(3); 当 $f(\lambda_k) \leq f(\mu_k)$ 时, 转步骤(4)。

(3) 置 $a_{k+1} = \lambda_k$, $b_{k+1} = b_k$, 取新的试探点:

$$\lambda_{k+1} = \mu_k, \quad \mu_{k+1} = a_{k+1} + 0.618(b_{k+1} - a_{k+1})$$

计算函数值 $f(\mu_{k+1})$ ，转步骤（5）。

（4）置 $a_{k+1} = a_k$ ， $b_{k+1} = \mu_k$ ，取新的试探点：

$$\lambda_{k+1} = a_{k+1} + 0.382(b_{k+1} - a_{k+1}), \quad \mu_{k+1} = \lambda_k,$$

计算函数值 $f(\lambda_{k+1})$ ，转步骤（5）。

（5）置 $k = k + 1$ ，返回步骤（2）。

例 2，求解极小化问题

$$\min \phi(\lambda) = 4(0.5 - 0.6059\lambda)^2 + 4(0.8 - 0.7955\lambda)^2 + e^{1.3-1.4014\lambda}$$

设定初始区间 $[a_1, b_1] = [0.5, 1.5]$ ，精度 $L = 0.05$ 。

使用 **0.618** 法做一维搜索，则迭代过程如下（见 PPT）：

k	a_k	b_k	λ_k	μ_k	$\phi(\lambda_k)$	$\phi(\mu_k)$	$b_k - a_k$
1	0.5000	1.5000	0.8820	1.1180	1.1095	0.9237	1.0000
2	0.8820	1.5000	1.1180	1.2639	0.9237	1.0757	0.6180
3	0.8820	1.2639	1.0279	1.1180	0.9305	0.9237	0.3819
4	1.0279	1.2639	1.1180	1.1738	0.9237	0.9582	0.2360
5	1.0279	1.1738	1.0836	1.1180	0.9171	0.9237	0.1459
6	1.0279	1.1180	1.0623	1.0836	0.9187	0.9171	0.0901
7	1.0623	1.1180	1.0836	1.0967	0.9171	0.9183	0.0557
8	1.0623	1.0967	1.0755	1.0836	0.9172	0.9171	0.0344

经过 7 次迭代有

$$b_8 - a_8 = 0.0344 < L = 0.05$$

近似极小点： $\bar{\lambda} \in [1.06238, 1.0968]$ ，可取近似最优解为

$$\bar{\lambda} = \frac{a_8 + b_8}{2} = \frac{1.06238 + 1.0968}{2} = 1.08$$

这个值和例 1 第一步的近似最佳步长 0.8324 不同。

注，使用 0.618 法时，每次在新区间中只需计算一个新点，另一个点复用自上次迭代所用的某个点，即可在新区间中构造出两个点来进一步缩短区间。

如何确定初始区间？

使用试探法，寻找三点，使函数值呈现“高-低-高”的关系，则函数值高的两个端点包含最小点，如下：

从任一点 a 出发（函数值 $f(a)$ ），前进（或后退）一步 δ ，得到 $f(a + \delta)$ ，如果 $f(a) > f(a + \delta)$ ，则再前进 2δ ，不断加倍前进，直到得到某两点 a', b' ，其关系为：

$$f(a') < f(b')$$

则初始区间确定为 $[a_0, b_0] = [a, b']$ 。


三、斐波那契 (Fibonacci) 法

问题：基于**两点试探**原理来缩短区间，则世界上速度最快的一维搜索方法是什么？


这个问题等价于：在给定**试探点数**的情况下，最长能将多长的区间缩短到长度为 1？

假设只允许搜索 1 次，显然只能将长度为 1 的区间“缩短”到 1：因为不能做 2 点比较而改变区间长度。

如果允许搜索 2 个点呢？如下图：



or




比较两个点的函数值： $f(1 - \varepsilon)$ 和 $f(1 + \varepsilon)$ ，可将长度为 2 的区间缩短为 $[0, 1 + \varepsilon]$ 或 $[1 - \varepsilon, 2]$ 。当 ε 很小时，缩短后的区间长度近似为 1。

所以，若只允许选择两个试探点，那么最长可将长度为 2 的区间缩短到长度为 1。

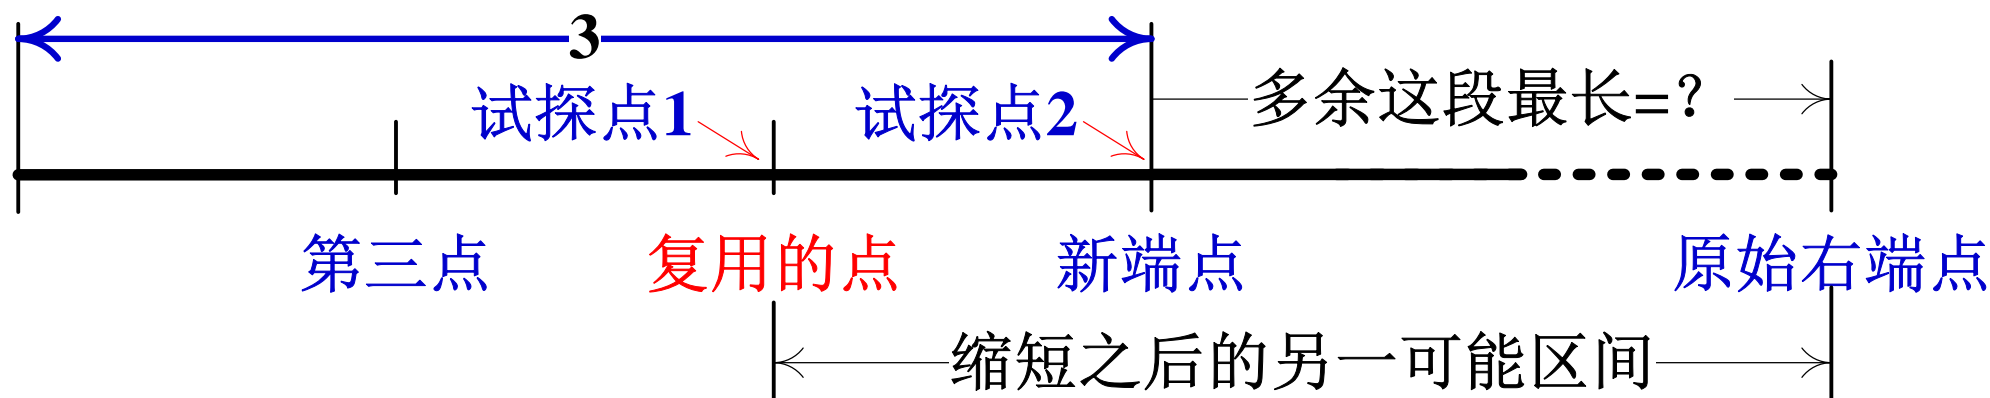
如果允许选 3 个点呢？

先通过 $1/3$ 和 $2/3$ 位置的两点将区间缩短为 2 ，然后再用第三个点将其缩短到 1 ——上次两点之一可**复用**：



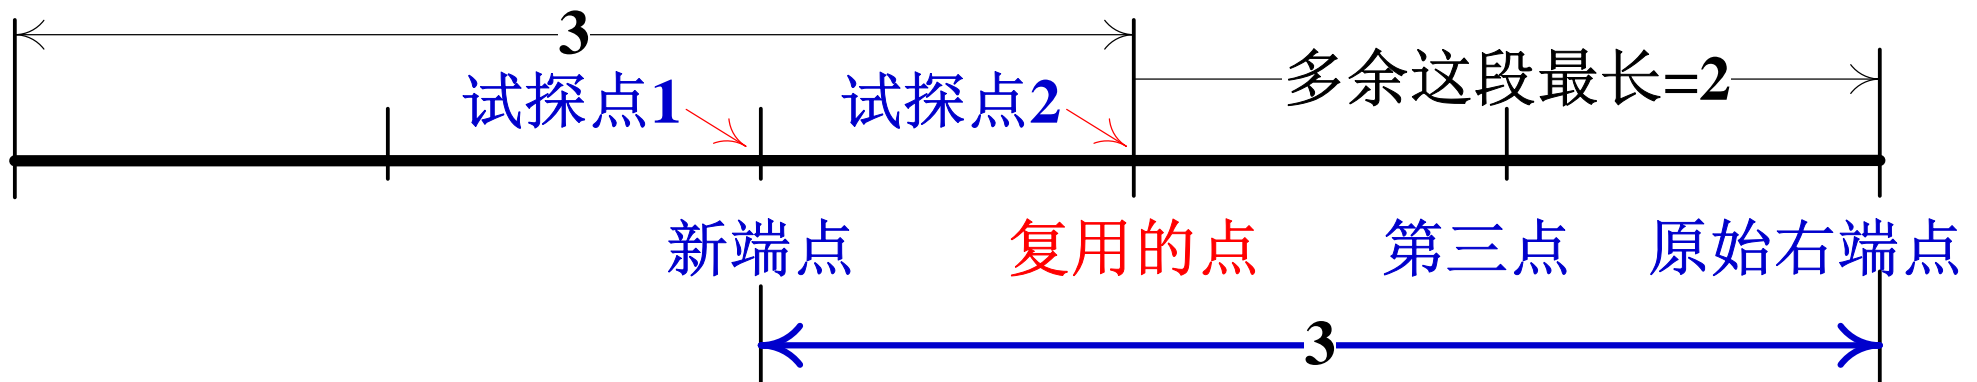
如果允许试探 4 个点呢？

可先用**两个点**将区间缩短为 3，再用**第三点**缩短为 2，再用**第四点**缩短为 1——上次迭代的两个点，一个成为**新端点**，另一个必须**复用**而参与下次函数值评估：



复用的点必须处于新区间的 $\frac{2}{3}$ 处，才能和**第三点**共同将区间长度进一步缩短为 2。

新区间也有可能是下面的情况：




因为缩短前并不知道缩短后的区间取左还是取右，所以必须是两种可能的结果都是 3，才能保证**必然**能将区间缩短为 3，结果多余的这段最大长度只能为 2。


因此试探 4 个点，可将最长为 5 的区间经 3→2 缩短为 1，且最初两个点位置分别在 $2/5$ 和 $3/5$ 处。

如果允许使用 5 个**试探点**呢？

先用两个点将区间缩短为 5，再缩为 3→2→1:



或



所以，5 个点可将最长为 8 的区间缩短到 1，且初始两点位置分别为 $3/8$ 和 $5/8$ 。

接着两点位置必须为 $2/5$ 和 $3/5$ （包括一个复用点），然后两点位置是 $1/3$ 和 $2/3$ ，最后是区间为 2 的需要缩短为 1，两点位置就是 $1/2$ 和 $(1 + \varepsilon)/2$ 。

上述给出的点数和可缩区间最大长度的关系为：

点数 k	0	1	2	3	4	5	6	7	8	9	10	...
最长区间 F_k	1	1	2	3	5	8	13	21	34	55	89	...

定义 2 上表的数字序列满足：

$$F_0 = F_1 = 1; F_{k+1} = F_k + F_{k-1}, (k = 1, 2, \dots)$$

称为 **Fibonacci 数列**。

可以看到，运用 **Fibonacci** 数列选 n 个点，就可将区间从 F_n 缩短到 1，**缩短比率**为 $1/F_n$ 。

一维搜索：给定初始区间 $[a_1, b_1]$ ，若以 **Fibonacci** 数列选**试探点**的位置，则最少需要多少个**试探点**才能将区间缩短为 L ？也即**缩短比率**为 $L/(b_1 - a_1)$ 。

因为 **Fibonacci** 数列选点法的**缩短比率**为 $1/F_n$ ，于是应有 $1/F_n \leq L/(b_1 - a_1)$ 。即，**试探点数** n 需满足：

$$F_n \geq \frac{b_1 - a_1}{L}$$

例，区间长度为3，要求缩短到0.05，求**试探点数**以及各**试探点**的位置。

解，需要 $F_n \geq \frac{b_1 - a_1}{L} = 60$ 。查 **Fibonacci** 数列表，应该取 $F_{10} = 89$ ，那么**试探点数**为10，位置分别为：

第一次迭代：34/89和55/89

第二次迭代：21/55和34/55

第三次迭代：13/34和21/34

第四次迭代：8/21和13/21

第五次迭代：5/13和8/13

第六次迭代：3/8和5/8

第七次迭代：2/5和3/5

第八次迭代：1/3和2/3


第九次迭代：1/2和 $\frac{1+\varepsilon}{2}$

而 **Fibonacci 法** 在迭代中计算**试探点**的公式为⁵:

$$\lambda_k = a_k + \frac{F_{n-k-1}}{F_{n-k+1}} (b_k - a_k), k = 1, \dots, n-1 \quad (16)$$

$$\mu_k = a_k + \frac{F_{n-k}}{F_{n-k+1}} (b_k - a_k), k = 1, \dots, n-1 \quad (17)$$

n 是计算函数值的次数；第 k 次迭代后，区间长度的**缩短比率**为 F_{n-k}/F_{n-k+1} 。



⁵ 注，**Fibonacci 法**确定试探点的位置时，是从后往前**倒着使用 Fibonacci 数列**的。

☆ Fibonacci 法与 0.618 法的关系

- (1) 两者都用于单峰函数的一维搜索。
- (2) 0.618 法可作为 Fibonacci 法的极限形式

$$\lim_{n \rightarrow \infty} F_{n-1}/F_n = 0.61803398874 \dots$$

(3) Fibonacci 法精度高于 0.618 法。给定相同试探次数，0.618 法的最终区间约比 Fibonacci 法长 17%。

(4) Fibonacci 法的缺点：需事先知道计算函数值（试探点）的次数（0.618 法不需要）。

在解决实际问题时，一般采用 0.618 法。