

第三节 拟牛顿法

一、拟牛顿法简介

二、拟牛顿条件及拟牛顿法的主要步骤

三、对称秩 1 校正

四、**DFP** 和 **BFGS** 校正（对称秩 2 校正）

一、拟牛顿法简介

牛顿法： $\mathbf{d}^{(k)} = -\nabla^2 f(\mathbf{x}^{(k)})^{-1} \nabla f(\mathbf{x}^{(k)})$ ，最大优点是在迭代点附近**收敛快**，因为对目标函数进行二次近似时，利用了目标函数的曲率信息（**Hesse 矩阵**）。

使用 Hesse 矩阵的缺点：求逆的计算量大、Hesse 矩阵可能非正定，导致牛顿方向可能不是下降方向。

愿望：寻找一种算法，既具有牛顿法收敛速度快的优点，又能克服计算工作量大、产生非下降方向等缺点。

拟牛顿法 (quasi-Newton method) 的基本思想：在迭代过程中只利用目标函数 $f(\mathbf{x})$ 和梯度 $\mathbf{g} = \nabla f(\mathbf{x})$ 信息，构造 Hesse 矩阵的近似逆矩阵，由此获得一个搜索方向，生成新的迭代点。

近似矩阵的不同构造方式，对应着拟牛顿法的不同变形。

拟牛顿法是一类收敛速度比较快的算法，是公认的比较有效的无约束优化方法。

二、拟牛顿条件及拟牛顿法的主要步骤

设迭代到当前点 $\mathbf{x}^{(k+1)}$ ，将目标函数 $f(\mathbf{x})$ 在点 $\mathbf{x}^{(k+1)}$ 处作二阶 Taylor 近似：

$$\begin{aligned} f(\mathbf{x}) \approx & f(\mathbf{x}^{(k+1)}) + \nabla f(\mathbf{x}^{(k+1)})^T (\mathbf{x} - \mathbf{x}^{(k+1)}) \\ & + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(k+1)})^T \nabla^2 f(\mathbf{x}^{(k+1)}) (\mathbf{x} - \mathbf{x}^{(k+1)}) \end{aligned}$$

上式进一步对 \mathbf{x} 求导得到

$$\nabla f(\mathbf{x}) \approx \nabla f(\mathbf{x}^{(k+1)}) + \nabla^2 f(\mathbf{x}^{(k+1)}) (\mathbf{x} - \mathbf{x}^{(k+1)})$$

则在点 $\mathbf{x}^{(k)}$ 处的梯度 $\nabla f(\mathbf{x}^{(k)})$ 近似为

$$\nabla f(\mathbf{x}^{(k)}) \approx \nabla f(\mathbf{x}^{(k+1)}) + \nabla^2 f(\mathbf{x}^{(k+1)})(\mathbf{x}^{(k)} - \mathbf{x}^{(k+1)})$$

即 $\nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)}) \approx \nabla^2 f(\mathbf{x}^{(k+1)})(\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)})$

记

$$\mathbf{q}^{(k)} = \nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)}); \quad \mathbf{p}^{(k)} = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$$

有

$$\mathbf{q}^{(k)} \approx \nabla^2 f(\mathbf{x}^{(k+1)})\mathbf{p}^{(k)}$$

若 Hesse 矩阵 $\nabla^2 f(\mathbf{x}^{(k+1)})$ 可逆, 则

$$\mathbf{p}^{(k)} \approx \nabla^2 f(\mathbf{x}^{(k+1)})^{-1} \mathbf{q}^{(k)}$$

当第 k 次迭代结束时, 即可计算出 $\mathbf{p}^{(k)}$ 和 $\mathbf{q}^{(k)}$ 。

如果能用上式信息估计出 $\nabla^2 f(\mathbf{x}^{(k+1)})^{-1}$, 则下一步迭代的牛顿方向: $\mathbf{d}^{(k+1)} = -\nabla^2 f(\mathbf{x}^{(k+1)})^{-1} \nabla f(\mathbf{x}^{(k+1)})$ 就可以知道。

直接估计 $\nabla^2 f(\mathbf{x}^{(k+1)})^{-1}$ 的好处是可以避免求逆矩阵的计算量、以及保证对 $\nabla^2 f(\mathbf{x}^{(k+1)})$ 的正定性要求。

令 $\mathbf{H}_{k+1} \approx \nabla^2 f(\mathbf{x}^{(k+1)})^{-1}$

表示通过估计得到的点 $\mathbf{x}^{(k+1)}$ 处的 Hesse 矩阵的近似逆矩阵，那么应该有

$$\mathbf{p}^{(k)} \approx \mathbf{H}_{k+1} \mathbf{q}^{(k)} \quad (1)$$

(1) 式称为拟牛顿条件^①。

使用近似矩阵 \mathbf{H}_{k+1} ，则 $\mathbf{x}^{(k+1)}$ 处的迭代方向就应该是

$$\mathbf{d}^{(k+1)} = -\mathbf{H}_{k+1} \mathbf{g}_{k+1} = -\mathbf{H}_{k+1} \nabla f(\mathbf{x}^{(k+1)})$$

^① 意思就是说， \mathbf{H}_{k+1} “像” 牛顿方向所用的 $\nabla^2 f(\mathbf{x}^{(k+1)})^{-1}$ 。

拟牛顿法的核心公式：

$$\mathbf{p}^{(k)} \approx \mathbf{H}_{k+1} \mathbf{q}^{(k)}$$

$$\mathbf{d}^{(k+1)} = -\mathbf{H}_{k+1} \mathbf{g}_{k+1} = -\mathbf{H}_{k+1} \nabla f(\mathbf{x}^{(k+1)})$$

称为尺度矩阵。若找到了估计尺度矩阵 \mathbf{H}_{k+1} 的方法，就可以构造拟牛顿算法。

因为在迭代的每一步， \mathbf{H}_{k+1} 都不同，因此拟牛顿法也称为变尺度法。

拟牛顿法的计算步骤:

(1) **初始化**: 给定初始点 $\mathbf{x}^{(1)} \in \mathbb{R}^n$, 初始正定阵 $\mathbf{H}_1 \in \mathbb{R}^{n \times n}$, 允许误差 $\varepsilon \in (0,1)$; 计算 $\mathbf{g}_1 = \nabla f(\mathbf{x}^{(1)})$, 置 $k = 1$ 。

(2) **平稳点检验**: 若 $\|\mathbf{g}_k\| \leq \varepsilon$, 则停止计算; 否则, 计算搜索方向 $\mathbf{d}^{(k)} = -\mathbf{H}_k \mathbf{g}_k$ 。

(3) **一维搜索**: 求步长 λ_k , 令 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}$ 。

(4) **修正拟牛顿方程**: 计算 $\mathbf{g}_{k+1} = \nabla f(\mathbf{x}^{(k+1)})$, 并对矩阵 \mathbf{H}_k 进行校正, 得到 \mathbf{H}_{k+1} , 使之满足拟牛顿条件 (1); 置 $k = k + 1$, 转步骤 (2)。

关键在于, 如何构造近似矩阵 \mathbf{H}_{k+1} ? 有很多方法。

三、对称秩 1 校正

\mathbf{H}_k 与 Hesse 矩阵的逆一样，须是 n 阶对称正定阵。

构造 \mathbf{H}_{k+1} 的一般策略：初始矩阵 \mathbf{H}_1 取为某 n 阶对称正定矩阵，如单位阵 \mathbf{I}_n ，然后修正 \mathbf{H}_k 给出 \mathbf{H}_{k+1} 。

令

$$\mathbf{H}_{k+1} = \mathbf{H}_k + \Delta\mathbf{H}_k$$

$\Delta\mathbf{H}_k$ 称为校正矩阵。 $\Delta\mathbf{H}_k$ 的选取要求保持 \mathbf{H}_{k+1} 的可逆、对称、正定。

那么 $\Delta\mathbf{H}_k$ 应该是什么形式？

Sherman-Morrison 定理：已知矩阵 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 可逆，对

$\forall \mathbf{a}, \mathbf{b} \in \mathbb{R}^n$ ，若 $1 + \mathbf{b}^T \mathbf{A}^{-1} \mathbf{a} \neq 0$ ，那么

(1) $\bar{\mathbf{A}} = \mathbf{A} + \mathbf{a} \mathbf{b}^T$ 也是可逆的；

(2) $\bar{\mathbf{A}}$ 的逆矩阵 $\bar{\mathbf{A}}^{-1}$ 可直接计算为

$$\bar{\mathbf{A}}^{-1} = \mathbf{A}^{-1} + \frac{\mathbf{A}^{-1} \mathbf{a} \mathbf{b}^T \mathbf{A}^{-1}}{1 + \mathbf{b}^T \mathbf{A}^{-1} \mathbf{a}}$$

注（对称性），如果选择的上述向量 \mathbf{a}, \mathbf{b} 是同一个向量，比如： $\mathbf{z} = \mathbf{a} = \mathbf{b}$ ，那么若 \mathbf{A} 是对称可逆的，则新矩阵 $\bar{\mathbf{A}}$ 也是**对称可逆**的。

运用 S-M 定理的结论 (1) 构造 \mathbf{H}_k

确定 $\Delta\mathbf{H}_k$ 的方法之一，取

$$\Delta\mathbf{H}_k = \alpha_k \mathbf{z}^{(k)} \mathbf{z}^{(k)\text{T}}$$

$\mathbf{z}^{(k)} \in \mathbb{R}^n$ 是 n 维列向量，容易证明 $\Delta\mathbf{H}_k$ 对称且秩为 1。

令

$$\mathbf{H}_{k+1} = \mathbf{H}_k + \Delta\mathbf{H}_k$$

根据 Sherman-Morrison 定理的结论 (1)，如果上次迭代使用的矩阵 \mathbf{H}_k 是 Hesse 矩阵的逆矩阵，则矩阵 \mathbf{H}_{k+1} 也仍然对称、可逆。

$\Delta \mathbf{H}_k$ 的选择应满足拟牛顿条件 (1) 式, 即

$$\mathbf{p}^{(k)} = \mathbf{H}_{k+1} \mathbf{q}^{(k)} = \mathbf{H}_k \mathbf{q}^{(k)} + \alpha_k \mathbf{z}^{(k)} \mathbf{z}^{(k)\text{T}} \mathbf{q}^{(k)} \quad (2)$$

得到

$$\mathbf{z}^{(k)} = \frac{\mathbf{p}^{(k)} - \mathbf{H}_k \mathbf{q}^{(k)}}{\alpha_k \mathbf{z}^{(k)\text{T}} \mathbf{q}^{(k)}}$$

于是, $\Delta \mathbf{H}_k = \alpha_k \mathbf{z}^{(k)} \mathbf{z}^{(k)\text{T}}$ 变换为

$$\Delta \mathbf{H}_k = \alpha_k \mathbf{z}^{(k)} \mathbf{z}^{(k)\text{T}} = \frac{(\mathbf{p}^{(k)} - \mathbf{H}_k \mathbf{q}^{(k)}) (\mathbf{p}^{(k)} - \mathbf{H}_k \mathbf{q}^{(k)})^{\text{T}}}{\alpha_k (\mathbf{z}^{(k)\text{T}} \mathbf{q}^{(k)})^2}$$

为求上式分母, (2) 式两端左乘 $\mathbf{q}^{(k)\text{T}}$, 有

$$\mathbf{q}^{(k)\text{T}}\mathbf{p}^{(k)} = \mathbf{q}^{(k)\text{T}}\mathbf{H}_k\mathbf{q}^{(k)} + \alpha_k \mathbf{q}^{(k)\text{T}}\mathbf{z}^{(k)}\mathbf{z}^{(k)\text{T}}\mathbf{q}^{(k)}$$

于是有

$$\mathbf{q}^{(k)\text{T}}(\mathbf{p}^{(k)} - \mathbf{H}_k\mathbf{q}^{(k)}) = \alpha_k (\mathbf{z}^{(k)\text{T}}\mathbf{q}^{(k)})^2 \quad (3)$$

最终，得到秩 1 校正公式^②：

$$\mathbf{H}_{k+1} = \mathbf{H}_k + \frac{(\mathbf{p}^{(k)} - \mathbf{H}_k\mathbf{q}^{(k)})(\mathbf{p}^{(k)} - \mathbf{H}_k\mathbf{q}^{(k)})^{\text{T}}}{\mathbf{q}^{(k)\text{T}}(\mathbf{p}^{(k)} - \mathbf{H}_k\mathbf{q}^{(k)})} \quad (4)$$

令搜索方向 $\mathbf{d}^{(k+1)} = -\mathbf{H}_{k+1}\nabla f(\mathbf{x}^{(k+1)})$ ，做下一次的一维搜索即可。

^② 显然，根据 Sherman-Morrison 定理，若 $\mathbf{q}^{(k)\text{T}}(\mathbf{p}^{(k)} - \mathbf{H}_k\mathbf{q}^{(k)}) > 0$ ，则(4)式决定的 \mathbf{H}_{k+1} 必然可继承 \mathbf{H}_k 的对称正定性。

对称秩 1 校正的收敛性

可以证明：秩 1 校正一定条件下收敛，且具有二次终止性。

秩 1 校正的局限性

(1) 仅当 $\mathbf{q}^{(k)\text{T}}(\mathbf{p}^{(k)} - \mathbf{H}_k \mathbf{q}^{(k)}) > 0$ 时，由 (4) 式得到的 \mathbf{H}_{k+1} 才能确保正定性，而这一点是没有保证的。

(2) 即使 $\mathbf{q}^{(k)\text{T}}(\mathbf{p}^{(k)} - \mathbf{H}_k \mathbf{q}^{(k)}) > 0$ ，因计算时舍入误差的影响，也可能导致 $\Delta \mathbf{H}_k$ 无界，从而产生数值计算上的困难。

四、对称秩 2 校正

(一) DFP 算法

DFP 方法由 **Davidon** 首先提出，后来又被 **Fletcher** 和 **Powell** 改进，得到 **DFP** 校正公式

$$\Delta \mathbf{H}_k = \frac{\mathbf{p}^{(k)} \mathbf{p}^{(k)T}}{\mathbf{p}^{(k)T} \mathbf{q}^{(k)}} - \frac{\mathbf{H}_k \mathbf{q}^{(k)} \mathbf{q}^{(k)T} \mathbf{H}_k}{\mathbf{q}^{(k)T} \mathbf{H}_k \mathbf{q}^{(k)}} \quad (5)$$

$$\mathbf{H}_{k+1} = \mathbf{H}_k + \frac{\mathbf{p}^{(k)} \mathbf{p}^{(k)T}}{\mathbf{p}^{(k)T} \mathbf{q}^{(k)}} - \frac{\mathbf{H}_k \mathbf{q}^{(k)} \mathbf{q}^{(k)T} \mathbf{H}_k}{\mathbf{q}^{(k)T} \mathbf{H}_k \mathbf{q}^{(k)}} \quad (6)$$

可验证，该校正得到的矩阵 \mathbf{H}_{k+1} 满足拟牛顿条件 (1)。

秩 2 校正

(5) 式的第一项提供了一个关于向量 $\mathbf{p}^{(k)}$ 的对称秩 1 校正，第二项也提供了一个关于向量 $\mathbf{H}_k \mathbf{q}^{(k)}$ 的对称秩 1 校正，根据 **Sherman-Morrison** 定理，若 \mathbf{H}_k 对称可逆，则得到的 \mathbf{H}_{k+1} 也对称可逆。

但总的来看，上述校正方法提供的校正矩阵 $\Delta \mathbf{H}_k$ 的秩为 2，因此称为秩 2 校正。

尺度矩阵的正定性

Sherman-Morrison 定理只保证了每步迭代得到的尺度矩阵是对称可逆的，但不能保证是正定的。

下述定理 1 进一步保证了上述系列矩阵 \mathbf{H}_i 总是**正定矩阵**，所以迭代方向能使函数值下降。

定理 1：若 $\mathbf{x}^{(k)}$ 处的梯度 $\mathbf{g}_k \neq \mathbf{0}$, ($k = 1, \dots, n$)，则**DFP**方法构造的矩阵 \mathbf{H}_k , ($k = 1, \dots, n$)为**对称正定矩阵**。

证明：用归纳法可证（略）。

DFP 方法计算步骤:

- (1) 给定初始点 $\mathbf{x}^{(1)}$, 允许误差 $\varepsilon > 0$ 。
- (2) 置 $\mathbf{H}_1 = \mathbf{I}_n$, 计算 $\mathbf{g}_1 = \nabla f(\mathbf{x}^{(1)})$, 置 $k = 1$ 。
- (3) $\mathbf{d}^{(k)} = -\mathbf{H}_k \mathbf{g}_k = -\mathbf{H}_k \nabla f(\mathbf{x}^{(k)})$, 沿 $\mathbf{d}^{(k)}$ 做一维搜索:
 $\lambda_k = \arg \min_{\lambda \geq 0} f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)}) \rightarrow \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}$
- (5) 检验是否满足收敛准则, 若 $\|\nabla f(\mathbf{x}^{(k+1)})\| \leq \varepsilon$, 则停止迭代, 得到极小点 $\bar{\mathbf{x}} = \mathbf{x}^{(k+1)}$; 否则, 转步骤 (6)。
- (6) 若 $k = n$, 则令 $\mathbf{x}^{(1)} = \mathbf{x}^{(k+1)}$, 返回步骤 (2) —— 初点重置, 重新启动算法; 若 $k < n$, 转步骤 (7)。

(7) 求校正矩阵, 令

$$\mathbf{p}^{(k)} = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$$

$$\mathbf{g}_{k+1} = \nabla f(\mathbf{x}^{(k+1)})$$

$$\mathbf{q}^{(k)} = \nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})$$

$$\Delta \mathbf{H}_k = \frac{\mathbf{p}^{(k)} \mathbf{p}^{(k)\text{T}}}{\mathbf{p}^{(k)\text{T}} \mathbf{q}^{(k)}} - \frac{\mathbf{H}_k \mathbf{q}^{(k)} \mathbf{q}^{(k)\text{T}} \mathbf{H}_k}{\mathbf{q}^{(k)\text{T}} \mathbf{H}_k \mathbf{q}^{(k)}}$$

$$\mathbf{H}_{k+1} = \mathbf{H}_k + \frac{\mathbf{p}^{(k)} \mathbf{p}^{(k)\text{T}}}{\mathbf{p}^{(k)\text{T}} \mathbf{q}^{(k)}} - \frac{\mathbf{H}_k \mathbf{q}^{(k)} \mathbf{q}^{(k)\text{T}} \mathbf{H}_k}{\mathbf{q}^{(k)\text{T}} \mathbf{H}_k \mathbf{q}^{(k)}}$$

置 $k = k + 1$, 返回步骤 (3) 。

例 1: DFP 法求解: $\min f(\mathbf{x}) = 2x_1^2 + x_2^2 - 4x_1 + 2$

取初始点 $\mathbf{x}^{(1)} = (2, 1)^T$, 及初始矩阵 $\mathbf{H}_1 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ 。目

标函数的梯度 $\mathbf{g} = \nabla f(\mathbf{x}) = \begin{bmatrix} 4(x_1 - 1) \\ 2x_2 \end{bmatrix}$ 。

第 1 次迭代: $\mathbf{g}_1 = \nabla f(\mathbf{x}^{(1)}) = \begin{bmatrix} 4 \\ 2 \end{bmatrix}$, $\mathbf{d}^{(1)} = -\mathbf{H}_1 \mathbf{g}_1 = \begin{bmatrix} -4 \\ -2 \end{bmatrix}$;

一维搜索:

$$\min_{\lambda \geq 0} f(\mathbf{x}^{(1)} + \lambda \mathbf{d}^{(1)}) = 3 - 20\lambda + 36\lambda^2$$

解得 $\lambda_1 = 5/18$ 。计算新点:

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \lambda_1 \mathbf{d}^{(1)} = \begin{bmatrix} 8/9 \\ 4/9 \end{bmatrix}, \quad \mathbf{g}_2 = \begin{bmatrix} -4/9 \\ 8/9 \end{bmatrix}$$

第 2 次迭代: $\mathbf{p}^{(1)} = \mathbf{x}^{(2)} - \mathbf{x}^{(1)} = \lambda_1 \mathbf{d}^{(1)} = \begin{bmatrix} -10/9 \\ -5/9 \end{bmatrix},$

$$\mathbf{q}^{(1)} = \mathbf{g}_2 - \mathbf{g}_1 = \begin{bmatrix} -40/9 \\ -10/9 \end{bmatrix}$$

校正矩阵:

$$\mathbf{H}_2 = \mathbf{H}_1 + \frac{\mathbf{p}^{(1)} \mathbf{p}^{(1)\text{T}}}{\mathbf{p}^{(1)\text{T}} \mathbf{q}^{(1)}} - \frac{\mathbf{H}_1 \mathbf{q}^{(1)} \mathbf{q}^{(1)\text{T}} \mathbf{H}_1}{\mathbf{q}^{(1)\text{T}} \mathbf{H}_1 \mathbf{q}^{(1)}} = \frac{1}{306} \begin{bmatrix} 86 & -38 \\ -38 & 305 \end{bmatrix}$$

令 $\mathbf{d}^{(2)} = -\mathbf{H}_2 \mathbf{g}_2 = \frac{4}{17} \begin{bmatrix} 1 \\ -4 \end{bmatrix}$

从 $\mathbf{x}^{(2)}$ 出发, 沿方向 $\mathbf{d}^{(2)}$ 搜索: $\min_{\lambda \geq 0} f(\mathbf{x}^{(2)} + \lambda \mathbf{d}^{(2)})$

解得 $\lambda_2 = 17/36$, 计算新点

$$\mathbf{x}^{(3)} = \mathbf{x}^{(2)} + \lambda_2 \mathbf{d}^{(2)} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{g}_3 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

得到最优解 $\bar{\mathbf{x}} = (1, 0)^T$ 。

此例经两次搜索达到极小点, 这不是偶然的: 可以证明, DFP 方法具有二次终止性。

定理 2: 设用 DFP 方法求解下列问题:

$$\min f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{b}^T \mathbf{x} + c$$

\mathbf{A} 为 n 阶对称正定矩阵。取初点 $\mathbf{x}^{(1)} \in \mathbb{R}^n$, 令 \mathbf{H}_1 是 n 阶对称正定矩阵, 则成立:

$$\mathbf{p}^{(i)T} \mathbf{A} \mathbf{p}^{(j)} = 0, \quad 1 \leq i < j \leq k$$

$$\mathbf{H}_{k+1} \mathbf{A} \mathbf{p}^{(i)} = \mathbf{p}^{(i)}, \quad 1 \leq i \leq k$$

其中 $\mathbf{p}^{(i)} = \mathbf{x}^{(i+1)} - \mathbf{x}^{(i)} = \lambda_i \mathbf{d}^{(i)}, (\lambda_i \neq 0, k \leq n)$ 。

证明: 用归纳法可证 (略)。

推论: 在定理 2 的条件下, 必有 $\mathbf{H}_{n+1} = \mathbf{A}^{-1}$ 。

注意到, $\mathbf{p}^{(i)} = \mathbf{x}^{(i+1)} - \mathbf{x}^{(i)} = \lambda_i \mathbf{d}^{(i)}$, 所以定理 2 给出的 $\mathbf{p}^{(1)}, \dots, \mathbf{p}^{(k)}$ 关于 \mathbf{A} 共轭, 就等价于 $\mathbf{d}^{(1)}, \dots, \mathbf{d}^{(k)}$ 关于 \mathbf{A} 共轭。可见, DFP 方法构造的搜索方向是一组关于矩阵 \mathbf{A} 的共轭方向, 因此 DFP 方法具有二次终止性, 即对于正定二次函数, DFP 方法经有限步迭代必达全局极小点。

但是, 对于一般 (非二次) 函数, 目前还没有成功建立 DFP 方法的全局收敛性结果。

而对于一般的二次函数 (不一定凸), DFP 方法的收敛性如下:

定理 3: $f(\mathbf{x})$ 是 \mathbb{R}^n 上的二次连续可微实函数, 对任意 $\hat{\mathbf{x}} \in \mathbb{R}^n$, 存在常数 $m > 0$, 使得当水平截集 $C(\hat{\mathbf{x}})$ 的元素

$$\mathbf{x} \in C(\hat{\mathbf{x}}) = \{\mathbf{x} | f(\mathbf{x}) \leq f(\hat{\mathbf{x}})\},$$

以及 $\mathbf{y} \in \mathbb{R}^n$ 时, 有

$$m\|\mathbf{y}\|^2 \leq \mathbf{y}^T \nabla^2 f(\mathbf{x}) \mathbf{y}^{\textcircled{3}}$$

则 **DFP** 方法以一维搜索产生的序列 $\{\mathbf{x}^{(k)}\}$ 或终止于或收敛于 $f(\mathbf{x})$ 在 \mathbb{R}^n 上的惟一极小点。

^③ $\mathbf{y}^T \nabla^2 f(\mathbf{x}) \mathbf{y} > 0$ 则 $\nabla^2 f(\mathbf{x})$ 正定; 更直观的说, $\mathbf{y}^T \nabla^2 f(\mathbf{x}) \mathbf{y} \geq m\|\mathbf{y}\|^2$ 是要其 “足够正定”。

(二) BFGS 公式

Broyden, Fletcher, Goldfarb 和 Shanno 于 1970 年提出 BFGS 方法，比 DFP 公式要好，应用广泛。

BFGS 不直接考虑拟牛顿条件：

$$\mathbf{p}^{(k)} \approx \nabla^2 f(\mathbf{x}^{(k+1)})^{-1} \mathbf{q}^{(k)} = \mathbf{H}_{k+1} \mathbf{q}^{(k)}$$

而是考虑关系式：

$$\mathbf{q}^{(k)} \approx \nabla^2 f(\mathbf{x}^{(k+1)}) \mathbf{p}^{(k)} = \mathbf{B}_{k+1} \mathbf{p}^{(k)} \quad (7)$$

即先构造 \mathbf{B}_{k+1} ，然后通过求逆确定尺度矩阵 \mathbf{H}_{k+1} 。

$$\mathbf{H}_{k+1} = \mathbf{B}_{k+1}^{-1} \quad (8)$$

考察 DFP 公式:

$$\mathbf{p}^{(k)} \approx \mathbf{H}_{k+1} \mathbf{q}^{(k)} \text{ ——DFP}$$

和 BFGS 公式:

$$\mathbf{q}^{(k)} \approx \mathbf{B}_{k+1} \mathbf{p}^{(k)} \text{ ——BFGS}$$

显然, 矩阵 \mathbf{H}_{k+1} 和 \mathbf{B}_{k+1} 、向量 $\mathbf{p}^{(k)}$ 和 $\mathbf{q}^{(k)}$ 彼此分别处于对称的位置, 因此只要在 \mathbf{H}_k 的递推公式中互换 $\mathbf{p}^{(k)}$ 和 $\mathbf{q}^{(k)}$, 并用 \mathbf{B}_{k+1} 和 \mathbf{B}_k 分别取代 \mathbf{H}_{k+1} 和 \mathbf{H}_k , 就能得到 \mathbf{B}_k 的递推公式。

矩阵 \mathbf{B} 的 BFGS 修正（DFP 公式的对偶）公式：

$$\mathbf{B}_{k+1} = \mathbf{B}_k + \frac{\mathbf{q}^{(k)} \mathbf{q}^{(k)T}}{\mathbf{q}^{(k)T} \mathbf{p}^{(k)}} - \frac{\mathbf{B}_k \mathbf{p}^{(k)} \mathbf{p}^{(k)T} \mathbf{B}_k}{\mathbf{p}^{(k)T} \mathbf{B}_k \mathbf{p}^{(k)}} \quad (9)$$

对比 DFP:
$$\mathbf{H}_{k+1} = \mathbf{H}_k + \frac{\mathbf{p}^{(k)} \mathbf{p}^{(k)T}}{\mathbf{p}^{(k)T} \mathbf{q}^{(k)}} - \frac{\mathbf{H}_k \mathbf{q}^{(k)} \mathbf{q}^{(k)T} \mathbf{H}_k}{\mathbf{q}^{(k)T} \mathbf{H}_k \mathbf{q}^{(k)}}。$$

和 DFP 校正的（5）式类似，BFGS 校正矩阵的第一项提供了一个关于向量 $\mathbf{q}^{(k)}$ 的对称秩 1 校正，第二项提供了一个关于向量 $\mathbf{B}_k \mathbf{p}^{(k)}$ 的对称秩 1 校正，而总体上校正矩阵 $\Delta \mathbf{B}_k$ 的秩为 2，因此 BFGS 方法也是秩 2 校正。

运用 S-M 定理的结论 (2) 求逆

根据 Sherman-Morrison 定理, 若 \mathbf{B}_k 对称可逆, 则 \mathbf{B}_{k+1} 也对称可逆, 且其逆矩阵 \mathbf{B}_{k+1}^{-1} 可直接由定理的结果 (2) 给出。记,

$$\mathbf{H}_{k+1}^{\text{BFGS}} = \mathbf{B}_{k+1}^{-1}$$

可得到关于矩阵 \mathbf{H} 的 BFGS 公式为:

$$\mathbf{H}_{k+1}^{\text{BFGS}} = \mathbf{H}_k^{\text{BFGS}} + \left(1 + \frac{\mathbf{q}^{(k)\text{T}} \mathbf{H}_k \mathbf{q}^{(k)}}{\mathbf{p}^{(k)\text{T}} \mathbf{q}^{(k)}}\right) \frac{\mathbf{p}^{(k)} \mathbf{p}^{(k)\text{T}}}{\mathbf{p}^{(k)\text{T}} \mathbf{q}^{(k)}} - \frac{\mathbf{p}^{(k)} \mathbf{q}^{(k)\text{T}} \mathbf{H}_k + \mathbf{H}_k \mathbf{q}^{(k)} \mathbf{p}^{(k)\text{T}}}{\mathbf{p}^{(k)\text{T}} \mathbf{q}^{(k)}} \quad (10)$$

例 2: 用 BFGS 法求解问题

$$\min f(\mathbf{x}) = 2x_1^2 + x_2^2 - 4x_1 + 2$$

取初始点 $\mathbf{x}^{(1)} = (2, 1)^T$ 及初始矩阵 $\mathbf{H}_1^{\text{BFGS}} = \mathbf{I}_2$, $\varepsilon = 0$ 。

目标函数的梯度 $\mathbf{g} = \nabla f(\mathbf{x}) = \begin{bmatrix} 4(x_1 - 1) \\ 2x_2 \end{bmatrix}$, 所以

$$\mathbf{g}_1 = \nabla f(\mathbf{x}^{(1)}) = \begin{bmatrix} 4 \\ 2 \end{bmatrix}$$

第 1 次迭代: 搜索方向 $\mathbf{d}^{(1)} = -\mathbf{H}_1^{\text{BFGS}} \mathbf{g}_1 = \begin{bmatrix} -4 \\ -2 \end{bmatrix}$, 从 $\mathbf{x}^{(1)}$

出发作一维搜索: $\min_{\lambda \geq 0} f(\mathbf{x}^{(1)} + \lambda \mathbf{d}^{(1)}) = 3 - 20\lambda + 36\lambda^2$

解得 $\lambda_1 = 5/18$

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \lambda_1 \mathbf{d}^{(1)} = \begin{bmatrix} 8/9 \\ 4/9 \end{bmatrix}, \quad \mathbf{g}_2 = \begin{bmatrix} -4/9 \\ 8/9 \end{bmatrix}$$

$$\mathbf{p}^{(1)} = \mathbf{x}^{(2)} - \mathbf{x}^{(1)} = \begin{bmatrix} -10/9 \\ -5/9 \end{bmatrix}, \quad \mathbf{q}^{(1)} = \mathbf{g}_2 - \mathbf{g}_1 = \begin{bmatrix} -40/9 \\ -10/9 \end{bmatrix}$$

由 (10) 式计算出

$$\begin{aligned} \mathbf{H}_2^{\text{BFGS}} &= \mathbf{H}_1^{\text{BFGS}} + \left(1 + \frac{\mathbf{q}^{(1)\text{T}} \mathbf{H}_1 \mathbf{q}^{(1)}}{\mathbf{p}^{(1)\text{T}} \mathbf{q}^{(1)}}\right) \frac{\mathbf{p}^{(1)} \mathbf{p}^{(1)\text{T}}}{\mathbf{p}^{(1)\text{T}} \mathbf{q}^{(1)}} \\ &\quad - \frac{\mathbf{p}^{(1)} \mathbf{q}^{(1)\text{T}} \mathbf{H}_1 + \mathbf{H}_1 \mathbf{q}^{(1)} \mathbf{p}^{(1)\text{T}}}{\mathbf{p}^{(1)\text{T}} \mathbf{q}^{(1)}} = \frac{1}{162} \begin{bmatrix} 46 & -22 \\ -22 & 169 \end{bmatrix} \end{aligned}$$

第 2 次迭代：搜索方向 $\mathbf{d}^{(2)} = -\mathbf{H}_2^{\text{BFGS}} \mathbf{g}_2 = \begin{bmatrix} 20/81 \\ -80/81 \end{bmatrix}$

求解一维搜索：

$$\min_{\lambda \geq 0} f(\mathbf{x}^{(2)} + \lambda \mathbf{d}^{(2)}) = \frac{2}{729} (9 - 20\lambda)^2$$

解得 $\lambda_2 = 9/20$ 。

新的迭代点 $\mathbf{x}^{(3)} = \mathbf{x}^{(2)} + \lambda_2 \mathbf{d}^{(2)} = (1, 0)^T$ ，对应的函数值 $f(\mathbf{x}^{(3)}) = 0$ 。

$\mathbf{g}_3 = \nabla f(\mathbf{x}^{(3)}) = 0$ ，所以 $\mathbf{x}^{(3)} = (1, 0)^T$ 就是最优解。

拟牛顿法的优点:

- (1) 迭代中仅需一阶导数, 不必计算 Hesse 矩阵;
- (2) H_k 正定, 所以算法产生的方向均为下降方向;
- (3) 具有二次终止性, 对于一般情形, 具有超线性收敛速率; 而且还具有 n 步二级收敛速率。

拟牛顿法的缺点:

BFGS 方法所需存储量较大, 但在当今世界存储不是最大的难题; 除非面对百万级甚至上亿个变量, 这才是需要注意的问题。

(三) 关于拟牛顿法的推广

DFP 和 BFGS 校正，都是由 $\mathbf{p}^{(k)}$ 和 $\mathbf{H}_k \mathbf{q}^{(k)}$ 构成的秩 2 校正，特点是它们的线性组合也可作为一种校正。

可将 DFP 和 BFGS 做线性组合，得到新的校正

$$\mathbf{H}_{k+1} = (1 - \theta_k) \mathbf{H}_{k+1}^{\text{DFP}} + \theta_k \mathbf{H}_{k+1}^{\text{BFGS}}$$

或者从 \mathbf{B}_k 矩阵入手 $\mathbf{B}_{k+1} = (1 - \phi_k) \mathbf{B}_{k+1}^{\text{BFGS}} + \phi_k \mathbf{B}_{k+1}^{\text{DFP}}$ 。

简单说，上述不同参数组合得到的拟牛顿矩阵不同，形成了一大类校正公式，称为 Broyden 族。前面的秩 1 校正也是这个族的成员之一。

基于 **Sherman-Morrison 定理** 的矩阵校正只是其中一种矩阵校正方法，除了 Broyden 族校正公式，使用其他矩阵校正方法也能得到不同公式，如 **Huang 族** 校正。

Broyden 族需要一个参数 θ_k 或 ϕ_k ，而 Huang 族需要三个参数。

Broyden 族是 Huang 族的一个子族。

作业题

1、分别用 DFP 法和 BFGS 法求解下述问题：

$$\min f(\mathbf{x}) = x_1^2 - 2x_1x_2 + 4x_2^2 + x_1 - 3x_2$$

取初始点 $\mathbf{x}^{(1)} = (1,1)^T$ 。

2、考虑习题 1 中 DFP 和 BFGS 方法各自所构造的搜索方向序列，完成下述计算：

(1) 考察各自的搜索方向是否关于 Hesse 矩阵共轭？

(2) 取初始点 $\mathbf{x}^{(1)} = (1,1)^T$ ，以相反顺序使用搜索方向重做一维搜索，指出与原搜索过程的异、同点。